

A Multi-Stage Bayesian Approach to Fit Spatial Point Process Models

Ren, Hooten et al. · *Spatial Statistics* 73 (2026)

Denilzon Robinho Tapara Tristan

Universidad Nacional del Altiplano Puno
Facultad de Estadística e Informática

Docente: Fred Cruz Torres · Estadística Espacial

15 de Mayo, 2026

¿Cuál es el problema y qué propone el paper?

Contexto

Los **Procesos Puntuales Espaciales (SPP)** modelan eventos aleatorios en el espacio: distribución de especies, sismos, crimen. Este paper se enfoca en el **Proceso de Poisson Inhomogéneo (IPP)**.

El problema: integral intratable

La verosimilitud del IPP contiene:

$$\Lambda(\mathcal{S}) = \int_{\mathcal{S}} \lambda(\mathbf{s}) d\mathbf{s}$$

No tiene forma cerrada $\Rightarrow$ cuadratura numérica en cada iteración MCMC. Muy

Solución propuesta

Un algoritmo **multi-etapa recursivo (PPRB)** que:

- No requiere tuning
- Paraleliza el cálculo de $\Lambda(\mathcal{S})$
- Es **exacto** (posterior conjunta)
- Es hasta **100× más rápido**

Pregunta central

¿Cómo ajustar modelos IPP bayesianos de forma **exacta, sin tuning y aprovechando cómputo paralelo**?

El IPP y sus Verosimilitudes

Función de intensidad

$$\lambda(\mathbf{s}) = \exp(\beta_0 + \mathbf{x}'(\mathbf{s})\boldsymbol{\beta})$$

- β_0 : controla la abundancia total N
- $\mathbf{x}(\mathbf{s})$: covariables espaciales
- $\boldsymbol{\beta}$: coeficientes a estimar

Factorización clave

$$\underbrace{[\{\mathbf{s}_i\}, n | \beta_0, \boldsymbol{\beta}]}_{\text{Completa}} = \underbrace{[\{\mathbf{s}_i\} | \boldsymbol{\beta}, n]}_{\text{Etapa 1}} \times \underbrace{[n | \beta_0, \boldsymbol{\beta}]}_{\text{Etapa 2}}$$

$$\text{con } [n | \beta_0, \boldsymbol{\beta}] = \text{Poisson}(\Lambda(\mathcal{S}))$$

Verosimilitud completa

$$[\{\mathbf{s}_i\}, n | \beta_0, \boldsymbol{\beta}] = \frac{\prod_{i=1}^n \lambda(\mathbf{s}_i)}{n! e^{\Lambda(\mathcal{S})}}$$

- ✓ Inferencia sobre N
- ✗ $\Lambda(\mathcal{S})$ en cada paso MCMC

Verosimilitud condicional

$$[\{\mathbf{s}_i\} | n, \boldsymbol{\beta}] = \frac{\prod_{i=1}^n \lambda(\mathbf{s}_i)}{(\Lambda(\mathcal{S}))^n}$$

- ✓ Aproximable con reg. logística
- ✗ β_0 no identificable

Extensión: Ventanas de Observación Compactas

Motivación: En imágenes aéreas los eventos solo se observan en ventanas delimitadas $\mathcal{W}_j$.


- $\mathcal{S}_0 = \mathcal{S} \setminus \bigcup_j \mathcal{W}_j$: área **no observada**
- Detección perfecta dentro de $\mathcal{W}_j$
- Sin detección fuera

Objetivo

Inferir la abundancia total N en todo $\mathcal{S}$, aunque solo observemos puntos en las ventanas.

Verosimilitud en ventanas

$$[\{\mathbf{s}_{ij}\}, \{n_j\} | \beta_0, \boldsymbol{\beta}] = \frac{\prod \prod \lambda(\mathbf{s}_{ij})}{n! e^{\Lambda(\cup_j \mathcal{W}_j)}}$$



Puntos rojos ($n = 580$): observados en ventanas. Grises: fuera de ventanas, no usados. Las ventanas cubren $\approx 50\%$ del dominio.

El Algoritmo Multi-Etapa PPRB

Etapa 1

Datos: $\{\mathbf{s}_i\}_{i=1}^n$

Ajustar verosimilitud condicional via regresión logística.

Salida: $\{\beta^{(k)}\}_{k=1}^K$

✓ Sin tuning

Etapa Intermedia

Entrada: $\{\beta^{(k)}\}_{k=1}^K$

Calcular $\Lambda^{(k)}(\mathcal{S})$ por cuadratura.

EN PARALELO

Salida: $\{\Lambda^{(k)}\}_{k=1}^K$

✓ Paso más costoso, ahora paralelizado

Etapa 2

Datos: n

Gibbs para β_0 :

$$\zeta^{(k)} \sim \text{Gamma}(a+n, b+\Lambda^{(k)})$$

M-H simplificado:


$$\alpha = \frac{[n|\beta_0^{(k)}, \beta^{(*)}]}{[n|\beta_0^{(k)}, \beta^{(k-1)}]}$$

✓ Posterior exacta

Cancelación clave

Al usar la posterior transitoria como propuesta, la verosimilitud condicional se **cancela** en el ratio M-H. Solo se evalúa $[n|\beta_0, \beta]$: muy rápido con los $\Lambda^{(k)}$ ya calculados

Diagrama del Algoritmo y Cuatro Estrategias



Rama izquierda (PG/HMC): muestreo bayesiano completo. Rama derecha (GLM-A/GLM-E): máxima verosimilitud. Ambas convergen en la Etapa 2.

PG — Pólya-Gamma

Bayesiano exacto. Gibbs sampler conjugado. Sin tuning pero **más lento**.

HMC — Hamiltonian Monte Carlo

Bayesiano exacto con NUTS (rstanarm). Sin tuning, buena mezcla MCMC.

GLM-A — GLM Aproximado

MLE con `glm()` en R. Muy rápido. Muestras i.i.d. (previene degeneración). Posterior aproximada.

GLM-E — GLM Exacto [recomendado]

MLE + corrección M-H exacta. Rápido, exacto y

Comparación de Estrategias y Predicción de N

Propiedades de cada estrategia

Propiedad	PG	HMC	GLM-E	GLM
Sin tuning	✓	✓	✓	✓
Totalmente Bayes.	✓	✓	×	×
Inferencia exacta	✓	✓	✓	×
Muestras i.i.d.	×	×	✓	✓

Recomendación

GLM-E: combina velocidad de MLE con exactitud bayesiana. Único con las 3 propiedades clave simultáneamente.

Predicción de abundancia total N

Los individuos fuera de ventanas (n_0) siguen:

$$[n_0 | \beta_0, \beta] = \text{Poisson}(\Lambda(\mathcal{S}_0))$$

Para cada muestra posterior k :



- 1 Calcular $\Lambda^{(k)}(\mathcal{S}_0)$
- 2 Muestrear $n_0^{(k)} \sim \text{Poisson}(\cdot)$
- 3 $N^{(k)} = n_0^{(k)} + n$

Resultado: distribución predictiva posterior de N con estimación puntual e incertidumbre.

Simulación: Configuración y Exactitud

Configuración:

- IPP con 3 parámetros: $\beta_0, \beta_1, \beta_2$
- $n = 580$ puntos en ventanas compactas
- $L = 640,000$ puntos de cuadratura
- Máquina: 24 núcleos, 3.68 GHz, 192 GB RAM
- Se comparan: Single-stage, PG, HMC, GLM-E, GLM-A




Intervalos creíbles al 95% para $\beta_0, \beta_1, \beta_2$. Todos los métodos recuperan el valor verdadero (línea punteada) con precisión equivalente al Single-stage.

Conclusión

Las distribuciones posteriores son **prácticamente**

Exactitud Conjunta y Eficiencia Computacional



Distribuciones posteriores bivariadas: GLM-E (rosa) vs. Single-stage (gris). Superposición casi perfecta $\Rightarrow$ exactitud en la posterior conjunta completa.

Segundos por muestra efectiva (menor = mejor)

Método	β_0	β_1	β_2
Single-stage	0.132	0.149	0.158
PG	0.027	0.028	0.037
HMC	0.014	0.014	0.018
GLM-E	0.001	0.001	0.001
GLM-A	0.001	0.001	0.001


Speedup

- PG, HMC: $\sim 10\times$ más rápidos
- GLM-E, GLM-A: $\sim 100\times$ más rápidos


Fuente: MLE rápida + paralelización de $\Lambda(\mathcal{S})$

↳ mayor ESS

Validación de N y Aplicación Real: Glacier Bay



Distribución posterior de N (simulación). Línea roja = valor verdadero. Bien centrada: validación del procedimiento.



Contexto ecológico

- Focas comunes (*Phoca vitulina*) en Glacier Bay, Alaska
- Usan icebergs para descansar, parir y mudar
- Los **cachorros** son el segmento más vulnerable al disturbio por embarcaciones

Datos del estudio

- Imágenes aéreas: 21 junio 2007
- $n = 452$ cachorros observados
- Cada imagen: $\approx 80 \times 120$ m
- Ventanas compactas = huellas de imagen

Covariables del Modelo y Red Neuronal (ELM)

Tres covariables (10×10 m, $L = 304,945$)

- 1 **Proporción de hielo:** segmentación de icebergs + kriging para extrapolación
- 2 **Batimetría:** profundidad NOAA (≈ 10 m)
- 3 **Distancia al glaciar:** distancia euclídea

Problema detectado

Modelo log-lineal **insuficiente** para capturar la heterogeneidad espacial. Verificado con L-function predictiva posterior.

Solución: SLFNN + ELM


$$\tilde{y}_i = \sum_{j=1}^q \tilde{\beta}_j g(\omega_j \cdot \mathbf{x}_i)$$

- $g(\cdot)$: activación GELU
- Pesos ω_j : **aleatorios y fijos** (sin backpropagation)
- $q = 5$ nodos, selección por AIC
- **W** reemplaza **X** en Etapa 1. Etapas 2 e Intermedia: **sin cambios**


Eficiencia

100,000 muestras posteriores en ≈ 3 minutos (24 núcleos)


Resultados: Distribución Espacial y Abundancia Total



Datos observados: 452 cachorros (puntos rojos). Grises = huellas de imagen.



*Abundancia media posterior en **todo** el dominio. Mayor abundancia en zonas de más hielo y aguas más profundas.*




Resultados

- $n = 452$ observados
- $\hat{N} = \mathbf{835.2}$
- $SD(N) = 27.7$
- ≈ 383 en zonas no fotografiadas


Validación del Modelo: L-Function

Sin red neuronal



L-function observada (roja) **fuera** del rango predictivo (gris) $\Rightarrow$ **mal ajuste**. El modelo log-lineal no captura el agrupamiento espacial real.

Con red neuronal (ELM)



L-function observada (roja) **dentro** del rango predictivo $\Rightarrow$ **buen ajuste**. La expansión NN captura la heterogeneidad espacial.

Nota: reemplaza la imagen derecha con la Figura 24 del paper para mostrar el contraste correcto.

Contribuciones principales

- 1 Algoritmo **PPRB multi-etapa** exacto: sin tuning, **100×** más rápido
- 2 Paralelización de $\Lambda(\mathcal{S})$: escala con núcleos
- 3 Cuatro estrategias de muestreo (recomendada: **GLM-E**)
- 4 Estimación de **abundancia total** N en dominios parcialmente observados
- 5 Expansión NN (ELM) compatible con el algoritmo

Limitaciones

- IPP asume independencia condicional: no modela clustering social
- Cuadratura escala con L
- LGCP completo: complejidades adicionales

Trabajo futuro

- Proceso de **Hawkes** (auto-excitante)
- Diseño adaptativo de ventanas
- Modelos **espacio-temporales**

¡Gracias por su atención!